

ملخص أول سيشن في مسار الداتا ساينس

شرح لما تم فهمه من الملاحظات المكتوبة + توضيح كل المصطلحات الجديدة عشان المذاكرة

اللي فهمته من الصور:

السيشن كانت مقدمة عامة (Overview) عن مجال الداتا، بتشرح إن مجال الداتا مش تخصص واحد، لكنه ٤ مسارات وظيفية مختلفة، كل مسار له مهامه وأدواته الخاصة، وهي: **Data Engineer**، **Data Analyst**، **Data Scientist**، **Machine Learning Engineer**. بعد كده اتشرحت خطوات مشروع الداتا ساينس بشكل عام (Business Understanding → Deployment)، ومفهوم ال Big Data ونصايح عامة للمجال.

1. مسار Data Engineer (مهندس بيانات)

وظيفته: تجهيز وبناء "الأنابيب" (Pipelines) اللي بتجمع الداتا من مصادرها، وتنصفها، وتخزنها بشكل منظم عشان باقي الأقسام (زي ال Data Scientist) يقدروا يستخدموها بسهولة.

- **SQL** ← لغة التعامل مع قواعد البيانات (Database)
- **Python** ← لكتابة السكريبتات اللي بتجمع/تنصف الداتا
- **Big Data** ← التعامل مع كميات ضخمة جداً من البيانات
- **Google Cloud, AWS, Docker** ← أدوات التخزين والمعالجة على ال Cloud، ووضع الأنظمة في حاويات (Containers)

2. مسار Data Analyst (محلل بيانات)

وظيفته: يفهم الداتا الموجودة حالياً، يحللها، ويطلع منها تقارير ورؤى (Insights) تساعد في اتخاذ قرارات، ويعرضها بشكل مبسّط للإدارة.

- **SQL ← DB** ← يسحب الداتا من قاعدة البيانات (Database) باستخدام SQL
- **Excel** ← لتنظيم وتحليل الداتا بشكل سريع
- **Power BI / Tableau** ← برامج لعمل لوحات بيانات (Dashboards) ورسومات تفاعلية للداتا
- **PowerPoint** ← لعرض النتائج والتقارير على الإدارة
- **Python** ← تحليل إضافي وأتمتة بعض المهام
- **Linear Regression** ← أبسط نموذج إحصائي للتنبؤ (هيتشرح تحت في الجدول)

3. مسار Data Scientist (عالم بيانات)

وظيفته: يبني نماذج ذكاء اصطناعي/تعلم آلي من الداتا التاريخية (Historical Data) عشان يتنبأ بالمستقبل (Forecasting)، وده أعمق من مجرد التحليل.

- **Excel, SQL** ← أساسيات التعامل مع الداتا
- **Python: Pandas, NumPy** ← مكتبات لتنظيم وتحليل الداتا بالأرقام والجداول
- **Matplotlib** ← مكتبة لعمل الرسومات البيانية (Charts)
- **Scikit-learn** ← مكتبة لبناء نماذج ال Machine Learning
- **Statistics, Probability, Mathematics** ← الأساس الرياضي اللي كل نماذج الداتا ساينس مبنية عليه
- **Deep Learning** ← فرع متقدم من ال Machine Learning يعتمد على الشبكات العصبية
- **Power BI / Tableau** ← لعرض نتائج التحليل بصرياً

• **Historical Data → Forecasting** ← استخدام بيانات الماضي للتنبؤ بالمستقبل

4. مسار Machine Learning Engineer (مهندس تعلم آلي)

وظيفته: يأخذ النموذج (Model) الي بناه ال Data Scientist ويحوّله لمنتج شغال فعلياً (Production) يقدر أي حد يستخدمه، من خلال بناء API ونشره على السيرفر.

• **MLOps** ← ممارسات لإدارة دورة حياة نماذج ال ML (زي DevOps لكن لا Machine Learning)

• **MLflow** ← أداة لتتبع تجارب النماذج المختلفة ومقارنتها

• **Hugging Face** ← منصة فيها آلاف النماذج الجاهزة (خصوصاً NLP) يمكن استخدامها مباشرة

• **Python → FastAPI** ← فريم وورك لبناء API سريع عشان النموذج يستقبل طلبات ويرد بنتائج

• **Docker** ← تحويل المشروع لحاوية (Container) تشتغل على أي جهاز أو سيرفر بنفس الطريقة

• **Git** ← نظام تتبع نسخ الكود (Version Control)

• **Front-end / Back-end** ← الواجهة الي المستخدم ييشوفها / والجزء الي ييشغل النموذج من الخلف

5. خطوات مشروع الداتا ساينس (Data Science Lifecycle)

دي الخطوات الي أي مشروع داتا ساينس يمر بيها بالترتيب:

1- **Business Understanding** — فهم المشكلة الي عايزين نحلها من ناحية البيزنس الأول، قبل ما نلمس أي داتا.

2- **Data Understanding & Preparation** — جمع الداتا المتاحة، فهمها، وتنظيفها من الأخطاء والقيم الناقصة.

3- **Modeling** — بناء نموذج التعلم الآلي التي هيحل المشكلة.

4- **Evaluation** — اختبار النموذج ومعرفة هل دقته كويسة وهل يحل المشكلة فعلاً ولا لأ.

5- **Deployment** — نشر النموذج عشان يبقى متاح للاستخدام الفعلي (وده اللي بيعمله ال ML Engineer).

6. ال Big Data وخصائصها (ال V's)

الداتا الضخمة (Big Data) بتتميز بأربع خصائص أساسية:

المعنى	الخاصية
حجم الداتا نفسه (كمية ضخمة جداً)	Volume
سرعة توليد ومعالجة الداتا (لحظياً أحياناً)	Velocity
تنوع أشكال الداتا (نصوص، صور، فيديو، أرقام...)	Variety
مدى دقة وموثوقية الداتا	Veracity

وبتنقسم كمان حسب الشكل إلى:

- **Structured** ← بيانات منظمة في جداول (زي الإكسل وقواعد البيانات)
- **Unstructured** ← بيانات مش منظمة (زي الصور، الفيديوهات، النصوص الحرة)

7. نصائح عامة (Advice)

- **Curiosity** ← الفضول وحب الاستكشاف والتعلم المستمر
- **Critical Thinking** ← التفكير النقدي وعدم قبول أي نتيجة من غير تحليل

- **Decision Making** ← القدرة على اتخاذ قرار بناءً على الداتا
- **Adaptability** ← المرونة والتأقلم مع تغير الأدوات والتكنولوجيا باستمرار

قاموس سريع لكل المصطلحات (للمراجعة)

المصطلح	تعريف مبسط
SQL	لغة برمجة للتعامل مع قواعد البيانات (استعلام، إضافة، تعديل بيانات)
Database (DB)	قاعدة البيانات التي يمتخزن فيها الداتا بشكل منظم
Python	لغة برمجة سهلة ومنتشرة جداً في مجال الداتا والذكاء الاصطناعي
Pandas	مكتبة بايثون للتعامل مع الجداول والبيانات (زي الإكسل لكن بالكود)
NumPy	مكتبة بايثون للعمليات الحسابية والمصفوفات بسرعة كبيرة
Matplotlib	مكتبة بايثون لرسم الرسوم البيانية (Charts/Graphs)
Scikit-learn	مكتبة بايثون جاهزة لبناء نماذج ال Machine Learning التقليدية
Excel	برنامج جداول بيانات لتحليل وتنظيم الداتا يدوياً
Power BI / Tableau	برامج لعمل لوحات معلومات (Dashboards) ورسومات تفاعلية من الداتا
Linear Regression	أبسط نموذج إحصائي يحاول يتنبأ بقيمة رقمية بناءً على علاقة خطية بين المتغيرات
Statistics & Probability	الإحصاء والاحتمالات، الأساس الرياضي لفهم وتحليل البيانات
Deep Learning	فرع من الذكاء الاصطناعي يستخدم الشبكات العصبية الاصطناعية لحل مشاكل معقدة (زي التعرف على الصور)
Historical Data	بيانات تم تسجيلها في الماضي، تُستخدم لتدريب النماذج
Forecasting	التنبؤ بالمستقبل بناءً على تحليل بيانات الماضي

كميات هائلة ومعقدة من البيانات صعب التعامل معها بالطرق التقليدية	Big Data
منصات سحابية (Cloud) لتخزين ومعالجة البيانات عن بُعد	Google Cloud / AWS
أداة لتحويل أي مشروع لحاوية (Container) تشتغل بنفس الطريقة على أي جهاز	Docker
نظام لتتبع التعديلات على الكود والتعاون بين المبرمجين	Git
مجموعة ممارسات لإدارة ونشر ومتابعة نماذج ال Machine Learning في الإنتاج	MLOps
أداة لتسجيل ومقارنة تجارب تدريب النماذج المختلفة	MLflow
منصة توفر آلاف النماذج الجاهزة (خصوصاً معالجة اللغة) للاستخدام المباشر	Hugging Face
مكتبة بايثون لبناء واجهات برمجية (API) بسرعة لتشغيل النموذج كخدمة	FastAPI
الواجهة التي ييشوفها المستخدم / والجزء البرمجي التي ييشغل من خلف الكواليس	Front-end / Back-end
بيانات منظمة في جداول / بيانات غير منظمة زي الصور والنصوص الحرة	Structured / Unstructured Data
الخصائص الأربعة التي بتوصف ال Big Data (الحجم، السرعة، التنوع، الموثوقية)	,Volume, Velocity, Variety Veracity

خلاصة بسيطة:

Data Engineer يجهز الداتا ← Data Analyst يفهمها ويحللها ← Data Scientist يبني منها نماذج تنبؤية ← ML Engineer ينشر النموذج ده عشان يشتغل فعلياً. كل واحد فيهم يحتاج Python و SQL كأساس، وبعدين كل مسار ليه أدواته المتخصصة.