

Data Science Methodology — In-Depth Guide with Examples

By Mohamed M Salama

عشان الشرح ما يفضلش نظري بس، هنمشي خطوة بخطوة مع مثال عملي متكرر طول الملف: شركة تجارة إلكترونية عايزة تقلل نسبة "تسرب العملاء" (Customer Churn) "يعني العملاء اللي بيوقفوا يشتروا أو يلغوا اشتراكهم. هنشوف إزاي المنهجية بتتطبق على المشروع ده من أول ما تكون فكرة لحد ما يبقى نموذج شغال فعليًا.

1. نظرة عامة على المنهجية

منهجية علم البيانات مش مجرد خطوات تقنية، هي إطار عمل (framework) بيساعد فريق العمل يتجنب أكبر غلطة بتحصل في المشاريع: إنك تبدأ تبني نموذج قبل ما تفهم المشكلة كويس. من غير منهجية واضحة، غالبًا الفريق بيضيع وقت في تنظيف بيانات مش مهمة، أو يبني نموذج معقد لمشكلة كان ممكن تتحلل بتحليل بسيط.

- **Foundational Data Science Methodology:** نهج عام لحل أي مشكلة بيانات بشكل منظم، بيتكون من مراحل متتالية من فهم المشكلة لحد نشر الحل.
- **CRISP-DM:** منهجية عالمية من 6 مراحل:
- Business Understanding → Data Understanding → Data Preparation → Modeling → Evaluation → Deployment. بتستخدم في أغلب الصناعات لأنها منظمة وقابلة للتكرار.

النقطة المشتركة بين المنهجتين إن العملية تكرارية (iterative) مش خطية (linear) يعني ممكن ترجع لمرحلة سابقة لو اكتشفت حاجة جديدة، وده طبيعي جدًا في علم البيانات.

مثال تطبيقي

فريق بيانات بدأ يبني نموذج تنبؤ بدون ما يسأل قسم المبيعات "يعني إيه عميل تسرب؟" — هل هو اللي مشتراش من 30 يوم؟ ولا اللي لغى اشتراكه رسميًا؟ من غير الاتفاق على التعريف ده الأول، أي نموذج هيتبني هيكون غلط من الأساس. المنهجية بتفرض إنك تحسم السؤال ده قبل ما تكتب أي كود.

2. صياغة المشكلة (Problem Formulation)

المرحلة دي هي الأساس اللي كل حاجة تانية بتتبنى عليه. الهدف هنا إنك تحول "مشكلة عمل (Business Problem)" غامضة زي "عايزين نزود المبيعات" لسؤال تحليلي محدد وقابل للقياس.

- **تحديد أهداف العمل:** لازم تعرف مين اللي هيستفيد من الحل، وإيه القرار اللي هيتاخذ بناءً على النتيجة.
- **إشراك أصحاب المصلحة:** اجتماعات وورش عمل مع الأقسام المعنية (مبيعات، تسويق، عمليات) عشان توضح الأهداف وتحدد الأولويات الحقيقية.
- **تحديد الأهداف:** تقسيم المشكلة الكبيرة لأجزاء صغيرة قابلة للتنفيذ، مع تواصل دوري لضمان إن الفريق ماشي في الاتجاه الصح.

مثال تطبيقي: مشروع تسرب العملاء

السؤال الغامض من الإدارة: "عايزين نقلل خسارة العملاء". بعد جلسات مع فريق المبيعات وخدمة العملاء، اتحول السؤال لصيغة تحليلية دقيقة: "إيه احتمالية إن عميل هيوقف الشراء خلال الـ 60 يوم الجاية، بناءً على سلوكه في آخر 90 يوم؟" — السؤال ده بقى قابل للقياس وممكن تبنى عليه نموذج.

3. منهج التحليل (Analytics Approach)

اختيار نوع التحليل مش قرار تقني بحث، هو نتيجة طبيعية لنوع السؤال الذي اتحدد في المرحلة التي فاتت. أهم فرق يجب فهمه هو الفرق بين أربع أنواع من التحليل:

- **Predictive Modeling (تنبؤي):** يجابوب على سؤال "احتمالية حدوث إيه؟" — زي التنبؤ بتسرب عميل أو احتمالية تعطل ماكينة.
- **Descriptive Analysis (وصفي):** يجابوب على سؤال "إيه اللي حصل ولية؟" — زي تحليل اتجاهات المبيعات في آخر سنة.
- **Classification Models (تصنيف):** حالة خاصة من التنبؤي، بتجاوب على سؤال بنعم/لا أو باختيار من فئات محددة.
- **Regression Models (انحدار):** بيتنبأ بقيمة رقمية مستمرة بدل فئة — زي التنبؤ بسعر شقة أو إيراد شهر قادم.

مثال تطبيقي

في مشروع التسرب: السؤال "هل العميل ده هيسيب الخدمة ولا لا؟" ده سؤال Classification (نعم/لا). لو بدل كده كان السؤال "قد إيه هيقل إنفاق العميل الشهر الجاي؟" كان هيبقى Regression. ولو كان السؤال "إيه أكثر شريحة عملاء بتلغي اشتراكها؟" كان هيبقى Descriptive Analysis (تحليل وصفي/تجميعي).

4. متطلبات البيانات (Data Requirements)

في المرحلة دي بتحدد "مكونات الوصفة" — أي بيانات محتاجها فعلاً عشان تجاوب على السؤال التحليلي. الخطأ الشائع هنا إنك تجمع كل البيانات المتاحة بدون تخطيط، وده بيضيع وقت ومجهود.

- **مصادر البيانات:** قواعد بيانات داخلية، أنظمة CRM، سجلات المعاملات، أو مصادر خارجية زي APIs.
- **طريقة الجمع:** هل هتسحبها بـ SQL query ؟ ولا محتاج تكامل مع نظام تاني؟ وهل البيانات دي موجودة أصلاً ولا محتاج تتجمع من الصفر؟
- **خطة المعالجة:** تحديد الصيغة والتنسيق المطلوبين، ومين هيكون مسؤول عن تحديث البيانات دورياً.

مثال تطبيقي

لمشروع التسرب، الفريق حدد إنه محتاج: بيانات المعاملات (تاريخ آخر عملية شراء، عدد المعاملات)، بيانات الفوترة (قيمة الاشتراك، طريقة الدفع)، بيانات دعم العملاء (عدد الشكاوى، مدة الرد)، وبيانات ديموغرافية (العمر، المدينة). لاحظ إنه محتاجش بيانات زي "لون واجهة الموقع اللي شافها العميل" — لأنها مش مرتبطة بالسؤال التحليلي.

5. جمع البيانات (Data Collection)

هنا بيبجي التنفيذ الفعلي لخطة المرحلة التي فاتت. مهم إنك تقيّم جودة البيانات فور جمعها، مش تسيبها لآخر لحظة.

- **أدوات الجمع:** استعلامات SQL على قواعد البيانات، أو استخدام APIs، أو حتى Web Scraping لو البيانات من مصدر خارجي.
- **تقييم الجودة:** استخدام الإحصاء الوصفي (Mean, Median, Std) والتصور البياني (Histograms, Box plots) لاكتشاف القيم الشاذة والبيانات الناقصة بسرعة.
- **قرار البيانات الناقصة:** لو نسبة البيانات الناقصة كبيرة، تقرر: تجمع بيانات إضافية، ولا تستخدم تعويض إحصائي (Imputation)، ولا تستبعد الحقل ده خالص.

مثال تطبيقي

لما الفريق سحب البيانات، لقى إن 7% من العملاء مفيش عندهم قيمة في حقل "تاريخ آخر تسجيل دخول". بعد الفحص، اتضح إنهم عملاء جداد سجلوا حديثاً، فالحل كان إضافة عمود جديد اسمه "عميل جديد (flag)" بدل ما يتعوض التاريخ بقيمة عشوائية ممكن تضلل النموذج.

6. فهم وتجهيز البيانات (Data Understanding & Preparation)

دي غالبًا أطول مرحلة في أي مشروع علم بيانات فعلي (ممكن تاخذ 60-70% من الوقت). بتتقسم لجزئين:

أ Data Understanding (فهم البيانات)

- تحليل استكشافي (EDA) لفهم توزيع كل متغير، والعلاقات بين المتغيرات المختلفة. (Correlation)
- التأكد إن العينة ممثلة للواقع — مثلاً مش كل البيانات من فئة عمرية واحدة بالغلط.

ب Data Preparation (تجهيز البيانات)

- التنظيف: إزالة التكرار (Duplicates) ومعالجة القيم الناقصة، وتصحيح التنسيق (زي توحيد صيغة التواريخ).
- Feature Engineering: إنشاء متغيرات جديدة من البيانات الخام تساعد النموذج يفهم أكثر — زي حساب "عدد الأيام من آخر عملية شراء" من عمود التاريخ.
- الترميز والتجهيز: تحويل المتغيرات النصية (categorical) لأرقام (One-Hot Encoding) وتوحيد مقاييس الأرقام (Normalization/Scaling).

مثال تطبيقي

من بيانات المعاملات الخام، الفريق عمل Feature Engineering وطلع متغيرات جديدة زي average_monthly_spend (متوسط الإنفاق الشهري) days_since_last_purchase (أيام من آخر شراء)، support_tickets_last_90_days (الشكاوى في آخر 90 يوم). المتغيرات دي فعليًا هي اللي بتخلي النموذج يقدر يميز بين عميل هيسيب الخدمة وعميل مستمر.

7. بناء النموذج (Modeling)

هنا بييجي التطبيق العملي للتحليل اللي اتحدد في مرحلة Analytics Approach. البيانات بتتقسم لمجموعة تدريب (Training Set) ومجموعة اختبار (Test Set) عشان نتأكد إن النموذج بيتعمم على بيانات جديدة مش بس بيحفظ البيانات القديمة.

- أمثلة خوارزميات: للتصنيف Logistic Regression، Decision Trees، Random Forest، XGBoost. للانحدار Linear Regression، Random Forest Regressor. وفي الحالتين ممكن استخدام Neural Networks لو البيانات كبيرة ومعقدة.
- التجربة والتحسين: تجربة عدة خوارزميات، وضبط البارامترات (Hyperparameter Tuning) عن طريق Grid Search أو Random Search مع استخدام Cross-Validation لتفادي الـ Overfitting.
- مقاييس التقييم: Accuracy، Precision، Recall، 1: score و AUC-ROC واختيار المقياس المناسب حسب طبيعة المشكلة (مش كل المقاييس مناسبة لكل مشكلة).

مثال تطبيقي

الفريق جرب Logistic Regression كنموذج أساسي (Baseline) وطلع دقة 78%. بعدين جرب Random Forest وطلع دقة 85%. لكن بما إن المشكلة حساسة (خسارة عميل حقيقي أهم من إنذار كاذب)، ركزوا على مقياس Recall بدل الـ Accuracy وحده، عشان يقللوا نسبة العملاء المعرضين للتسرب اللي النموذج ممكن "يفوتهم".

8. النشر (Deployment)

النموذج مالوش قيمة عملية لحد ما يتدمج في نظام شغال فعليًا. النشر بيتم غالبًا بشكل تدريجي عشان تقلل المخاطرة.

- طرق النشر: **Batch Scoring**: تشغيل النموذج على دفعة بيانات دوريًا (مثلًا كل ليلة). **Real-time API**: النموذج بيرد فورًا لما يتطلب منه تنبؤ.
- الإطلاق التدريجي: **(Canary Release)** إطلاق النموذج لنسبة صغيرة من المستخدمين الأول (زي 10%)، ومراقبة الأداء، قبل التوسع للكل.
- خطة الرجوع: **(Rollback)** لو النموذج الجديد أداؤه أسوأ من المتوقع، لازم يكون فيه خطة رجوع سريعة للنسخة القديمة.

مثال تطبيقي

نموذج التسرب انتشر كـ API متكامل مع نظام CRM، بحيث كل يوم النموذج يحسب "درجة خطورة التسرب" لكل عميل، وأي عميل درجته عالية بيظهر تلقائيًا في قائمة فريق الاحتفاظ بالعملاء (Retention Team) عشان يتواصلوا معاه بعرض خاص. الإطلاق كان الأول على 10% من العملاء لمدة شهر قبل ما يتعمم على الكل.

9. التغذية الراجعة (Feedback)

النموذج مش منتج نهائي، هو نظام حي محتاج مراقبة مستمرة. سلوك العملاء بيتغير، والسوق بيتغير، والنموذج ممكن "يصدا" (Model Drift) لو ما اتحدثش.

- **Gathering Feedback**: متابعة دقة النموذج بمرور الوقت، ومقارنة تنبؤاته بالنتائج الفعلية بعد ما تحصل.
- **Iterative Improvement**: لو الأداء بدأ يقل بسبب تغير سلوك المستخدمين، (Concept Drift) لازم يتعاد تدريب النموذج ببيانات جديدة بشكل دوري.

مثال تطبيقي

بعد 3 شهور من التشغيل، فريق البيانات لاحظ إن دقة النموذج قلّت من 85% لـ 76%. بعد التحقيق، طلع إن سلوك الشراء اتغير بسبب موسم تخفيضات جديد ما كانش موجود وقت التدريب. الحل كان إعادة تدريب النموذج ببيانات محدثة تشمل نمط الشراء الجديد.

10. سرد القصص بالبيانات (Storytelling)

أفضل نموذج في العالم مالوش قيمة لو محدش فهم نتيجته أو اتخذ قرار بناءً عليها. الـ **Storytelling** هو الجسر بين التحليل التقني والقرار الإداري.

- أهميته: تبسيط البيانات المعقدة لمعلومات سهلة الفهم لغير المتخصصين.
- عناصر القصة الجيدة: عرض واضح لهدف الرسالة، ورؤى مدعومة بالبيانات، وتصورات بصرية (رسومات بيانية) تدعم القصة مش تعقدها.
- مبادئ تصميم مهمة: اختيار نوع الرسم البياني المناسب (مثلًا **Bar chart** للمقارنات **Line chart**، للاتجاهات الزمنية)، وتجنب الرسومات المضللة زي الـ **3D Pie Charts**.

مثال تطبيقي

بدل ما فريق البيانات يعرض على الإدارة جدول بأرقام دقة النموذج التقنية، عملوا **Dashboard** بسيط بيوضح: عدد العملاء المعرضين للخطر هذا الشهر، القيمة المالية المتوقعة خسارتها لو ما اتصرفناش، والإيراد اللي اتحفظ فعليًا بعد تدخل فريق الاحتفاظ. العرض ده خلى الإدارة تاخذ قرار زيادة ميزانية فريق الاحتفاظ بالعملاء فورًا.

1. من المشكلة للمنهج: تحديد المشكلة واختيار أسلوب التحليل المناسب.
2. متطلبات وجمع البيانات: تحديد وجمع وفهم البيانات المطلوبة للتحليل.
3. فهم وتجهيز البيانات: تنظيف ومعالجة البيانات قبل التحليل، وبناء متغيرات جديدة مفيدة.
4. بناء النموذج: تطوير وتحسين النماذج للتنبؤ أو وصف الأنماط في البيانات.
5. النشر والتغذية الراجعة: نشر النموذج تدريجيًا، ومراقبته وإعادة تدريبه باستمرار.

النقاط الأهم: (Key Takeaways)

- علم البيانات عملية تكرارية تحتاج تحديد واضح للمشكلة، إشراك مستمر لأصحاب المصلحة، وتحسين متواصل — مش مشروع ينتهي بمجرد ما النموذج يشتغل.
- معالجة البيانات بشكل صحيح — من الجمع للتجهيز — أساسية لبناء نماذج فعالة، وغالبًا يتأخذ وقت أكثر من بناء النموذج نفسه.
- سرد القصص مهارة مهمة لعالم البيانات لتوصيل النتائج وتحويل الرؤى لقرارات فعلية — النموذج الأدق مش دائمًا اللي بيكسب، اللي بيتفهم ويتأخذ بيه قرار هو اللي بيكسب.